

PreCex: 反例驱动的综合前 RTL 缺陷定位与修复

佟亚龙

摘要—跨周期行为缺陷——弱测试平台仿真通过而形式验证失败的寄存器传输级（RTL）缺陷——是综合前最难定位与修复的问题之一。本文提出 **PreCex**，一个完全开源、反例驱动的 RTL 缺陷定位与修复流水线（iverilog/Yosys/SymbiYosys/Z3 加大语言模型，LLM）。它将失败的形式化反例转换为结构化证据，定位缺陷区域，生成最小补丁，并在带 **golden-first** 规则的有界模型检验（BMC）下重新验证。

在覆盖 6 个模块、7 类错误的 34 样本 L3 基准上（MiniMax M3 主实验 408 次），四种证据表征——原始日志、结构化证据（B）、反例语义化（C）与 FVDebug 式因果图（D）——在统一的 BMC 判据下修复率均达到 100

Index Terms—RTL 调试，形式验证，反例，大语言模型修复，变异分析

I. 引言

A. 背景与问题

寄存器传输级（RTL）设计复杂度持续增长，跨周期行为缺陷（L3：弱测试平台通过而形式验证失败）是综合前最难定位与修复的缺陷类型之一。此类缺陷通常隐藏在状态机迁移、握手时序或边界回绕逻辑中：简单断言行启发式无法命中注入点，仿真波形中的信息过载使人工与自动化定位都极为耗时。一旦缺陷进入综合与流片流程，修复成本呈数量级上升，因此在综合前准确、低成本地定位并修复 RTL 缺陷具有明确工程价值。

现有基于大语言模型（LLM）的修复流水线主要面临两类困难。其一，直接输入原始日志或波形，信息过载导致定位噪声，模型难以从数千行仿真记录中筛出真正的因果信号。其二，依赖参考模型（golden reference model）进行差分调试的方法在综合前阶段往往不可用——此时不存在可作为规范的金牌实现。近期工作（FVDebug、GROVE）证明了结构化反例理解的价值，但仍缺乏四点能力：（1）开源端到端流水线；（2）面向跨周期缺陷的系统性研究；（3）严格的验证充分性闭环；（4）证据表征的受控消融。

佟亚龙，作者单位（占位），中国。电子邮箱：tyl2003@nudt.edu.cn。

B. 设计动机

本文观察到，传递给 LLM 的证据表征（evidence representation）是一个关键但缺乏研究的维度：同样的模型能力下，证据如何组织直接决定定位精度与 token 成本。为此，我们在同一 34 样本 L3 数据集上（408 次 LLM 修复运行）系统比较四种证据设置：A 为原始反例日志与 VCD 头尾；B 为结构化证据（EvidenceEngine JSON）；C 为反例语义化（CexSemantizer 输出的周期事件、状态轨迹、故障锥与自然语言摘要）；D 为 FVDebug 式因果图（确定性提取）。

与此同时，本文强调修复判据本身必须接受检验：原协议采用 prove/k-归纳判据，但对带门控时序断言的 axi/uart 模块不收敛——golden 设计本身即返回 UNKNOWN，导致 78 个正确修复被误判为失败。据此我们确立了 **golden-first** 规则：任何修复判据必须首先在 golden 设计上通过，才可用于评判修复结果。

C. 贡献

本文的主要贡献如下：

- **开源反例驱动修复流水线**：基于 iverilog/Yosys/SymbiYosys/Z3 与 MiniMax M3 API 的端到端实现，完全可复现；配套 34 样本 L3 数据集，含 golden 双重校验与充分性审计。
- **证据表征受控消融**：统一 BMC 判据下四种设置修复率均达 100
- **验证充分性闭环**：强变异 88.5
- **判据翻案的方法论教训**：prove/k-归纳在门控时序断言上误判 78 个正确修复（golden 本身 UNKNOWN）；修复判据必须首先通过 golden 一致性校验，BMC 判据 + golden-first 规则是自动修复评测的可靠基准。

II. 相关工作

A. 反例驱动的调试与根因分析

FVDebug (Bai 等, 2025) [1] 是最接近的同类工作: 它从失败的形式化轨迹构建因果 DAG, 用批量 LLM 调用扫描可疑节点, 通过 agent 生成根因叙述并输出修复, 在两个工业反例上完成演示。PreCex 与其共享反例理解这一核心: 我们的设置 D 是 FVDebug 式因果图的确定性开源实现 (失败断言、故障锥、全周期状态轨迹与触发条件)。FVDebug 在三个维度上留有空缺, 而 PreCex 恰好控制: 其一, 它依赖商业工具链; 其二, 它没有报告证据表征的受控消融; 其三, 它不量化验证器充分性。PreCex 完全开源 (iverilog/Yosys/SymbiYosys/Z3), 在同一 34 样本数据集上比较四种证据表征, 并以变异分析、空泛性控制与独立 T2 审计评测验证器。

GROVE (Bai 与 Ren, 2025) [2] 将断言失败调试知识组织为分层知识树: 训练时以模型检验验证知识项, 测试时按预算感知检索, 一致提升 pass@1/pass@5。GROVE 与 PreCex 互补: GROVE 跨样本积累可复用知识, PreCex 消费单个失败反例, 在无历史存储的闭环中完成定位-修复-重验。GROVE 式知识层可作为本流水线的自然扩展。

开源 LLM 驱动形式验证 (Tran, 2026) [3] 采用与本文相同的开源工具链 (Yosys/SymbiYosys/Z3), 以 LLM 引导反例驱动迭代修复, 以 k-归纳证明或预算耗尽为停止条件, 在 6 个基准上仅可靠修复 1 个。该工作验证了开源管线的可行性并整理了失败模式; PreCex 的差异在于增加证据语义化层 (该工作将原始反例直接送入 LLM), 并在更大、受控的 L3 数据集上采用 golden-first 判据。

FormalRTL [4] 以软件参考模型作为形式化规范, 闭合规划、综合与等价检验循环, 并含一个反例简化器, 只高亮失败功能与不匹配信号。PreCex 不作参考模型假设: 仅凭断言与反例工作, 这正是综合前无黄金模型时的常见设置。

ChipAgents RCA (商业, 2026) [5] 将波形理解引擎与 prover-verifier agent 对及自一致性排序结合, 报告了工业部署中对三周期竞争条件的定位。它佐证跨周期根因分析是真实工业痛点, 但作为闭源黑盒, 未提供任何消融细节。

B. 基于 LLM 的 RTL 修复

VeriPilot [6] 使用黄金参考模型与 CDFG 信号追踪, 将 CVDP 上的 GPT-4o 修复率从 54.3% 提升至 85.71%。**VeriDebug** [7] 学习对比嵌入并引导修正, 在定位加类型联合任务上取得 64.7% 的 Acc@1。**RTLFixer** [8] 采用检索增强修复语法错误。三者均非反例驱动: 分别依赖参考模型、微调嵌入或仅做语法级修复。PreCex 明确针对综合前无参考模型的场景, 将证据表征而非模型能力作为研究变量。

Fixbench-RTL [9] 与 **HDL-FixBench** [10] 是修复基准: Fixbench-RTL 覆盖语法、功能与安全域; HDL-FixBench 面向仓库级实例 (OpenTitan/CVA6/Ibex 共 57 个实例, 最佳模型 40.3%, 被 ICLR 2026 拒稿)。HDL-FixBench 被拒稿所暴露的缺陷正是 BugBench-PS 着力规避的: 规模过小、多样性不足、补丁阈值存在争议、缺少非 LLM 基线以及数据污染风险。

C. 断言生成与验证充分性

AssertLLM [11] 与 **AssertLLM2** [12] 从自然语言规格加波形生成 SVA 断言; AssertLLM2 引入 83 设计的断言基准, 并以变异驱动的 bug-hunting 设置评测断言。**AssertGen** [13] 通过思维链提取验证目标并桥接跨层信号, 采用变异测试覆盖率评估。**LASSO** [14] 生成带显式空泛性检查与覆盖反馈的安全属性, 在 OpenTitan 中发现 5 个真实缺陷。**LintLLM** [15] 以变异缺陷注入执行 LLM 代码检查。

这些工作生成或审计断言; PreCex 消费断言加反例以完成定位与修复。其评测实践 (变异覆盖、空泛性、bug-hunting) 构成了本文充分性审计的方法学先例: 88.5% 强变异与 81.8% 常量变异被杀, 删除变异空泛性控制通过。

D. 基准与评测方法

工具执行裁决 (tool-execution adjudication) 是 EDA-AI 领域公认的评测实践: Rule2DRC [16] (ICML 2026) 比较 13,921 条布局规则结果, PostEDA-Bench [17] 评估 145 个 DRC/PPA 任务, 均通过执行设计工具裁决。PreCex 遵循同一原则: 修复成功由编译、弱测试平台回归与形式 BMC 裁决, 从不依赖 LLM 自述。工程语义数据集 (OpenRTLSet [18]、EDA-Schema-V2 [19]、ChipLingo [20]) 为本文证据模式设计提供参考。

表 I

设计空间定位：与已有工作的证据表征、开源性与评测闭环对比

工作	证据表征	开源	跨周期	消融	充分性
FVDebug	因果图	否	部分	否	否
GROVE	知识树	否	否	否	否
2607.28877	原始反例	是	部分	否	否
FormalRTL	反例简化 + 参考模型	部分	否	否	否
VeriPilot	CDFG+ 参考模型	否	否	否	否
VeriDebug	学习嵌入	否	否	否	否
AssertLLM2	断言生成	—	—	—	变异驱动
PreCex	原始/结构化/语义化/因果图	是	34 样本	A/B/C/D	变异/空泛/T2

E. 本文定位

表 I 汇总了与已有工作的定位差异。PreCex 的三项差异化能力均有受控实验佐证：(1) 完全开源、可复现的反例驱动流水线；(2) 四设置证据表征消融与配对显著性检验；(3) 带验证充分性闭环（变异、空泛、独立 T2 审计）的跨周期 L3 基准。此外，判据翻案审计（第 V-F 节）贡献了一条方法论经验：修复判据必须先用 golden 设计验证，才能用于评判修复。

III. 方法

A. 系统架构




图 1. PreCex 流水线：失败的形式化反例经解析生成结构化证据（B），可选语义化（C）或汇总为因果图（D），由 LLM 修复器生成最小 diff，并在 golden-first 的 BMC 判据下重新验证；失败结果回灌循环。

整体架构如图 1 所示。PreCex 由四个核心组件与两个支撑元素构成（开源工具链 iverilog、Yosys [21] 与 SymbiYosys [22]）。EvidenceEngine 将 cex.log 解析为统一 JSON 结构（错误类型、模块、文件、行号、代码片段、信号、触发条件、失败阶段与失败步）。CexSemantizer 将 VCD 转换为周期事件表、状态轨迹、故障锥与自然语言摘要（window=8 压缩）。LocalRepairer 以设计、断言与证据为输入（MiniMax M3, temperature 0.2），输出

表 II

四种证据表征设置（受控消融）

设置	证据	提取方式	单次成本
A	原始 cex.log + VCD 头尾	无	基线
B	evidence.json（结构化）	确定性	低
C	semantics.json（周期事件 + 状态轨迹 + 故障锥 + 摘要, window=8）	LLM 语义化	高
D	FVDebug 式因果图（失败断言 + 故障锥 + 全周期状态轨迹 + 触发条件）	确定性（零 LLM）	最低

定位与最小统一 diff，重试不超过两轮。Verifier 执行三关验证：iverilog 编译零错误、弱测试平台仿真全绿、sby smtbmc+z3 BMC 无反例（主判据），并叠加 golden 双重校验。支撑元素为实验变量控制组件与 BugBench-PS 数据集资产。

B. 证据引擎与反例语义化

EvidenceEngine 以失败断言、错误类型与失败阶段的统一模式组织反例，输出稳定可解析的 evidence.json。CexSemantizer 在此基础上生成周期事件表（每周期信号变化）、状态轨迹（跨周期信号演化）、故障锥（与失败断言相关的信号依赖闭包）与自然语言摘要。实验表明主数据集反例普遍较短（中位 6 周期），window=8 压缩的聚合收益仅 4.1%——语义化的成本由摘要文本主导而非轨迹长度，这一观察直接支撑了第 V-D 节的成本分析。

C. 四种证据表征

各设置的证据内容与提取成本见表 II。四种设置使用同一 prompt 家族，仅替换证据段，以控制偏置。A 为基线，B 与 D 均为零 LLM 成本的确定性提取，C 引入一次 LLM 语义化调用，是四者中唯一的额外推理成本来源。

D. 修复判据：golden-first 规则

主判据为 BMC（verify.sby），与 golden 验证（verify_golden.sby）一致。原协议采用 prove/k-归纳（verify_repair.sby）作为修复判定，但在带门控时序断言的 axi/uart 模块上不收敛：golden 设计本身返回 UNKNOWN（rc=4），旧判据下 78 个正确修复被误判为失败。同一正确修复（s33 的 B 设置 seed0、s17 的 B

设置 seed1) 在 bmc 下 PASS、prove 下 FAIL 的实测直接暴露了这一矛盾。

据此确立 golden-first 规则：任何修复判据必须首先在 golden 设计上通过（判据-黄金一致性检查），方可用于评判修复。BMC 重验 303/303 全部通过，修复率由 74.3% 修正为 100%。prove/k-归纳仅作为辅助参考保留，不再作为失败判据。

E. 验证充分性审计

为量化断言集能否捕获注入缺陷（充分性），本文对 golden 设计执行三类变异：

- **强变异**：比较器反转等强语义变异（d16），400 个变异体，88.5% 被杀。
- **常量变异**：替换参数常量 DATA_W/ADDR_W/DEPTH/DIV/HALF，484 个变异体，81.8% 被杀。
- **删除变异**：移除断言，作为空泛性控制，全部通过（若删除断言后仍能杀变异，说明断言冗余）。

模块级分析显示 axi 与 fifo 的强变异杀死率为 100%，而 uart_rx 最弱（强变异 55.0%、常量变异 40.9%）——结构断言对波特时序常量漂移不敏感，这是已记录的局限并列为未来工作。此外，T2 审计以确定性脚本替代 LLM 自证，对全部含 diff 的修复（A/B/C 306 条 + D 102 条）检查三类违规：接口/端口/参数变更、断言篡改、证据闭环一致性，均零失败；loc_dev 中位数为 0（A/B/C 62.7% 精确命中，D 69.6%），补丁规模均值 2.1 行、最大值 6 行，证明修复保持最小化。

IV. 实验设置

A. 数据集 BugBench-PS

BugBench-PS 包含 34 个 L3 样本（s04-s37），覆盖 6 个开源教学级模块：fifo_sync、uart_tx、uart_rx、axi_lite_slave、fsm_ctrl 与 counter_alu，错误类别共 7 类：状态迁移（24 样本）、握手（12 样本）、复位（18 样本）、FIFO 满空（15 样本）、边界回绕（21 样本）、位宽截断（9 样本）与边沿（3 样本），合计每设置 102 条定位记录。每个样本经 golden 双重校验（buggy 设计在 BMC 下 FAIL，golden 设计 PASS），并通过唯一性/结构审计（34/34 通过）。断言行、信号行与随机行启发式基线全部失败（0% 或 0.50% 期望），证明注入缺陷位于功能/时序逻辑而非断言块。

B. 评测协议与成本记账

主实验为 34 样本 $\times$ 4 设置 $\times$ 3 seeds = 408 次真实 LLM 修复运行（MiniMax M3, temperature 0.2）。修复成功由 BMC 加 golden 双重校验裁决。成本按 API token 记账（MiniMax M3 公开单价：输入 0.60 美元/百万 token、输出 2.40 美元/百万 token，为估算值而非平台账单），主实验合计 11.22 美元（408 次运行，平均 0.0275 美元/次）；含预研与重跑在内的完整账本为 17.79 美元（1312 次调用）。运行采用并行调度：8 并发（运维阶段因 API/验证阻塞调整为 4 并发加 420 秒硬超时与断点续跑），全量重验 68 个 BMC 任务在 3.4 分钟内完成。跨模型评测使用 DeepSeek v4-flash（temperature=0, OpenAI 兼容端点），在 A/B/C 三设置上对 34 个 L3 样本重跑 seed 0（102 次调用，成本 \$0.34）；L2 门禁对照使用 24 个 L2 样本 $\times$ A/B/C（72 次调用，成本 \$0.29）。两者均采用与主实验一致的 BMC 判据与 golden 双重校验。

C. 可复现性

全部实验基于开源工具链：iverilog 12.0、verilator 5.020、yosys 0.33、SymbiYosys (sby, smtbmc+z3 引擎) 与 Python 3.12，运行于 WSL。证据链生成命令为 python3 scripts/build_evidence.py --samples s04-s37 --real --window 8；主实验为 python3 scripts/run_experiments_parallel.py --samples s04-s37 --settings A,B,C --seeds 0,1,2 --jobs 8（结果合并到 experiments/runs/experiments_results_parallel.json）；充分性量化、T2 审计与 BMC 重验分别由 verify_sufficiency.py、t2_audit.py、reverify_bmc.py 完成。所有 LLM 调用强制写入 token 账本（experiments/runs/token_ledger.jsonl, 1312 条），成本按输入 $\times$ 输入单价 + 输出 $\times$ 输出单价线性估算（MiniMax M3: 0.60/2.40 美元每百万 token，标注为估算口径）。数据集 BugBench-PS（34 样本，6 模块 $\times$ 7 错误类型）与复现命令链一并开源，见仓库 REPRO.md。

D. 非 LLM 基线

为确立 LLM 定位的非平凡性，在相同精确匹配口径（候选行等于 buggy_inject_line, 34 样本）下评测三类简单启发式：首个断言行、任意断言行、首个提及失败

表 III
四设置主实验结果 (N=102 每设置, 修复率按 BMC 判据)

设置	n	定位 Top-1	修复率	Tokens	成本 (USD)
A 原始日志	102	47.1%	100%	1.99M	2.78
B 结构化证据	102	61.8%	100%	1.76M	2.72
C 反例语义化	102	56.9%	100%	3.50M	4.17
D 因果图	102	49.0%	100%	1.07M	1.56

信号的证据行, 以及随机行期望。结果全部为 0% (随机行期望 0.50%), MiniMax M3 主实验四设置 47.1–61.8% 的定位精度远超这些基线, 结构化证据 (B) 的 61.8% 约为随机期望的 120 倍。

V. 实验结果与分析

A. 结果概览




图 2. 各设置的定位 Top-1 精度 (柱) 与 LLM 成本 (折线)。B 相对 A 与 D 的精度优势统计显著 (配对 McNemar)。

表 III 与图 2 汇总了四设置的主实验结果。发现 1: 统一 BMC 判据下, 四种证据表征的修复率均达 100%——证据表征不决定能否修复, 而决定多准、多便宜。

发现 2: 在 MiniMax M3 上, 结构化证据 (B) 定位精度最优 (61.8%); 因果图 (D) 成本最低 (1.56 美元, 较 B 低 43%, token 最少 1.07M), 精度 49.0%, 呈现清晰的精度/成本权衡。语义化 (C) 成本为 B 的 1.5 倍以上, 精度无显著增益 (与预研阶段一致)。

统计显著性: 对 102 条逐样本定位结果做配对 McNemar 检验: B 对 A $p = 0.0035$ (显著)、B 对 D $p = 0.0164$ (显著)、B 对 C $p = 0.404$ (不显著)、C 对 D $p = 0.186$ (不显著)。全部对比均报告, 包括不显著项。




图 3. 错误类别 × 设置的定位 Top-1 精度热力图。困难类别排序 (状态迁移/握手低于位宽截断/边沿) 在全部设置中成立。

表 IV

错误类别 × 设置定位精度 (每设置 n: 状态迁移 24、握手 12、复位 18、FIFO 满空 15、边界回绕 21、位宽截断 9、边沿 3)

错误类别	A	B	C	D
状态迁移	33.3%	37.5%	37.5%	25.0%
握手	16.7%	33.3%	33.3%	41.7%
复位	55.6%	72.2%	83.3%	44.4%
FIFO 满空	53.3%	53.3%	60.0%	46.7%
边界回绕	42.9%	81.0%	57.1%	57.1%
位宽截断	88.9%	100%	66.7%	100%
边沿	100%	100%	100%	100%

表 V

变异分析充分性 (针对 GOLDEN 设计)

变异家族	变异体	被杀	比率
强变异 (比较器反转)	400	354	88.5%
常量变异 (参数常量替换)	484	396	81.8%
删除变异 (断言移除)	抽样	全部 PASS	空泛性控制

B. 错误类型分析

图 3 与表 IV 给出按错误类别分解的定位精度。发现 3: 单点语义错误易定位 (边沿 100%、位宽截断 85.2%), 跨状态与握手错误难定位 (状态迁移 36.1%、握手 27.8%), 该难度排序在全部设置中稳定。B 在边界回绕 (81.0%)、位宽截断 (100%) 与状态迁移 (37.5%) 上最佳或并列最佳; D 在握手类别上最高 (41.7%, 每设置 n=12, 小样本需谨慎解读)。

C. 修复可信度: 充分性与 T2 审计

变异分析结果见表 V。T2 确定性审计对 408/408 条修复全部通过: 接口变更 0、断言篡改 0、证据闭环失

败 0; loc_dev 中位数 0 (A/B/C 62.7% 精确、D 69.6%)。补丁最小化由均值 2.1 行、最大值 6 行佐证。

D. 成本与性能

主实验总成本 11.22 美元 (408 次运行, 平均 0.0275 美元/次); 分设置为 A 2.78、B 2.72、C 4.17、D 1.56 美元, token 分别为 1.99M、1.76M、3.50M、1.07M。C 的成本来自语义化摘要文本而非轨迹长度: 主数据集反例中位 6 周期, window=8 压缩仅带来 4.1% 的聚合缩减。验证性能方面, BMC 8 并发重验 68 个任务用时 3.4 分钟; 单样本 golden 验证耗时以 axi 约 87 秒、uart_rx 约 151 秒为上限。

E. L2 门禁对照: 假阳性率

为量化数据集纯度门禁 (弱测试平台可观测) 对系统能力的区分度, 我们构造 24 个 L2 样本 (单周期功能错误, 弱 tb FAIL + formal fail 双检通过, 覆盖 axi/counter/fifo/fsm/uart_rx/uart_tx 六模块), 并用 DeepSeek v4-flash 在 A/B/C 三设置下各评测一次 (72 次调用, 成本 \$0.29)。结果: L2 修复率 (BMC 判据) 为 91.7% (66/72), L3 基线为 100%, 仅差 8.3 个百分点——弱 tb 门禁不构成系统能力的显著分界, 系统能把绝大多数单周期错误当作 L3 修复到三通过。

未修复的 6 次调用全部集中在两个 L2 样本 (l2_uarttx_01 起始位握手失效、l2_uarttx_02 状态跳转至 STOP), 三设置均为 INCONCLUSIVE, 是 uart_tx 协议交互类缺陷难以定位修复的又一证据。按设置看, L2 定位精度 B 最高 (50.0% vs A 45.8%、C 41.7%), 与 L3 上 B 的定位优势方向一致但幅度小 (n=24, 小样本)。该对照实验说明: 证据表征的相对优势主要体现于跨周期 (L3) 缺陷, 对单周期可观测 (L2) 缺陷区分度有限; 论文将 L2 假阳性率 (91.7%) 如实报告为门禁纯度代价。

F. 判据翻案的方法论教训

发现 4: 原 prove/k-归纳判据误判 78 个正确修复 (golden 本身在 prove 下 UNKNOWN), BMC 重验 303/303 全部通过, 修复率由 74.3% 修正为 100%。这一翻案说明: 修复判据必须先经 golden 一致性校验, 否则判据缺陷会系统性污染修复率、定位精度与成本等全部下游指标。PreCex 将 BMC 判据与 golden-first 规则固化为评测协议的一部分, 作为可复用的方法论产出。

表 VI

跨模型主实验对比 (MiniMax M3 vs DeepSeek v4-flash, seed 0 严格配对, n=34 每设置; 修复率按 BMC 判据)

设置	MM 定位	DS 定位	MM 修复	DS 修复
A 原始日志	41.2%	55.9%	100%	100%
B 结构化证据	64.7%	55.9%	100%	100%
C 反例语义化	64.7%	67.6%	100%	100%

G. 模块与错误类型的交互效应

发现 5: B 的定位优势并非均匀分布, 而是集中在数值、位宽与边界类缺陷。按模块与错误类型交叉统计 (408 次运行, BMC 判据): 在 axi_lite_slave 的边界回绕类缺陷上 B 的 top-1 定位为 83.3% (C 为 33.3%), 在 counter_alu 边界回绕上为 100% (C 为 33.3%), 在 fifo_sync 位宽截断上为 100% (A/C 为 66.7%); 而在 uart_tx/uart_rx 的握手与状态跳转类缺陷上, 四设置 top-1 定位全部为 0%, 修复率仍为 100%。这表明结构化证据的增益来自”算术/位宽/边界”语义清晰、便于精确行号映射的缺陷; 对协议交互类缺陷, 证据表示难以改善定位精度, 但形式再验证闭环仍能保证修复正确。

H. 证据可解释性的多模型评估

探索性评估: 为量化 B/C/D 证据表示的可解释性差异, 我们以 5 维 Likert 量表 (完整性、可读性、因果性、可操作性、可信度, 1-5 分) 对 10 个样本的 C (反例语义化) 与 D (FVDebug 式因果图) 证据进行多模型评分 (DeepSeek v4-flash 与 MiniMax M3, temperature=0, 40 次调用, 总成本 \$0.11)。C 证据的因果性与可操作性跨模型一致中等 (ICC(2,1) 0.656 与 0.753), 而完整性、可读性、可信度一致低 (≈ 0); D 证据五维 ICC 全部 ≈ 0 , 两模型几乎无一致。该结果说明: LLM 作为可解释性代理评分的跨模型一致性仅在”因果链是否可追踪”这一维度上可信, 其余维度主观差异大, 需人工标定; 论文将此作为探索性结果, 并如实报告 LLM 代理评分的局限。

I. 跨模型鲁棒性

发现 6: 证据表征的定位优势是模型依赖的 (表 VI)。为检验 “单提供商威胁”, 我们用 DeepSeek v4-flash (temperature=0) 在 34 个 L3 样本的 A/B/C 三设置上重跑 seed 0 (102 次调用, 成本 \$0.34, 全部 BMC 三通过)。与 MiniMax M3 的 102 条 seed 0 严格配对比较:

修复率两模型均为 100% (BMC 判据, McNemar 不一致对 0), 跨模型差异不在“能否修复”而在定位与成本——DeepSeek 总体定位 59.8% (vs MiniMax 56.9%), 但按设置看, MiniMax 上 B 最优 (64.7%, 对 A 的配对 McNemar $p = 0.0078$), DeepSeek 上 B 被 C 反超 (67.6%, $p = 0.125$, $n=34$ 小样本不显著)。DeepSeek 成本为同任务 MiniMax 的约 1/9.4 (\$0.34 vs \$3.19), 且首次尝试即全部通过 (attempts=1 vs 1.78)。

方法论含义: 跨模型对比必须先统一修复判据口径; 若以旧 prove 判据 (MiniMax 225/306) 对比 DeepSeek 的 BMC 结果 (102/102), 会错误得出“DeepSeek 修复率显著更高”。统一 BMC 口径后该差异消失。这进一步支持本文的核心主张: 在判据可靠的前提下, 证据表征的相对效应应限定于所测模型, 论文不宣称跨模型普遍性。

VI. 结论

本文提出 PreCex, 一个开源、反例驱动的综合前 RTL 缺陷定位与修复流水线, 并系统研究了此前反例理解类系统未受控的证据表征维度。在含 408 次主实验 (MiniMax M3)、102 次跨模型重跑 (DeepSeek v4-flash, seed 0 严格配对) 与 72 次 L2 门禁对照评测的 34 样本跨周期 (L3) 基准上, 主要结论如下:

- 四种证据表征 (原始日志、结构化证据、反例语义化、FVDebug 式因果图) 在一致的 BMC 判据下修复率均达 100%; 表征决定定位的精度与成本, 而非能否修复。
- 结构化证据 (B) 在 MiniMax M3 上定位精度最高 (61.8%), 对原始日志 (47.1%, $p = 0.0035$) 与因果图 (49.0%, $p = 0.0164$) 的优势统计显著; 因果图 (D) 成本最低 (1.56 美元对 2.72 美元, 低 43%); 语义化 (C) 增加成本而无显著精度增益。
- 修复可信度有据可依: 强变异 88.5%、常量变异 81.8% 被杀, 空泛性控制通过, 独立 T2 审计 408/408 通过, 接口与断言篡改均为零, 定位偏差 (loc_dev) 中位数为零。
- 判据翻案审计 (以 BMC 替代 prove/k-归纳, 辅以 golden-first 规则) 为自动修复流水线提供方法论教训: 评测判据本身必须先经 golden 设计验证, 才能用于评判修复。
- 跨模型鲁棒性: 修复率在 MiniMax M3 与 DeepSeek v4-flash 上均为 100% (BMC 口径), 但定位优势模

型依赖——B 的优势仅在 MiniMax 上成立 (64.7% 对 A 41.2%, $p = 0.0078$), DeepSeek 上被 C 反超 (67.6%); DeepSeek 成本为 MiniMax 的约 1/9.4, 可作低成本复现通道。

未来工作包括: 向工业协议与更大断言集扩展、更强的变异家族、多提供商多模型评测、GROVE 式跨样本知识层, 以及以形式证明为奖励的强化学习修复。

A. 局限性

内部效度: 所有结果以 BMC 为主判据; 对带门控时序断言的模块, BMC 探测到缺陷深度加 2 并与 golden 验证交叉核对, 但 BMC 深度上界并非完备性保证。LLM 推理是流水线唯一随机成分 (3 seeds 配对统计), 解析、提取与验证均为确定性。修复成功定义要求编译、弱测试平台回归与 BMC 无反例; 不改变断言集的补丁仍可能在属性集之外改变行为, T2 审计通过接口与断言篡改检查约束该风险, 但并非等价性检验。

外部效度: 基准含 34 个教学级模块样本, 不宣称工业协议覆盖; 握手与状态迁移仍是最难定位类别 (27.8% 与 36.1%), uart_rx 的波特时序常量变异杀死率弱 (常量 40.9%), 是结构断言对时序常量漂移不敏感的已记录局限。常见模块可能出现在 LLM 训练语料中, 本文以构造日期记录、逐样本来源与错误类别多样性缓解, 但无法完全排除残余记忆。主实验 408 次运行均使用 MiniMax M3; 跨模型重跑 (102 次 DeepSeek) 显示修复率跨模型一致但定位优势模型依赖, 故本文的证据表征结论限定于所测模型, 绝对值可能随模型版本变化。另, L2 门禁对照显示假阳性率高达 91.7% (弱 tb 门禁不构成能力分界), 且 uart_tx 握手/状态类 L2 样本 (12_uarttx_01/02) 三设置全部未修复, 是协议交互类缺陷的系统性短板。

构造效度: loc_top1 记录模型首选中候选行是否落入注入缺陷的参考 diff; 修复率按 BMC 判据计量; 成本按 API token 记账; 统计声明基于逐样本配对 McNemar 检验, 且报告全部对比 (含不显著项)。

参考文献

- [1] Y. Bai, G. B. Hamad, C.-T. Ho, S. Suhaib, and H. Ren, “FVDebug: An LLM-driven debugging assistant for automated root cause analysis of formal verification failures,” arXiv:2510.15906, 2025.
- [2] Y. Bai and H. Ren, “Learning to debug: LLM-organized knowledge trees for solving RTL assertion failures,” arXiv:2511.17833, 2025.
- [3] H. T. Tran, “Open-source LLM-driven formal verification: A multi-agent pipeline for RTL repair,” arXiv:2607.28877, 2026.

- [4] K. Li, M. Li, X. Wen, S. Zhao, J. Wu, J. Huang, and Q. Xu, “FormalRTL: Verified RTL synthesis at scale,” 2026. [Online]. Available: <https://formind.netlify.app/files/papers/FormalRTL.pdf>
- [5] WhaleChip, “WhaleChip uses ChipAgents to compress root cause analysis into minutes,” SemiWiki, 2026. [Online]. Available: <https://semiwiki.com/eda/chipagents-ai/371464-whalechip-uses-chipagents-to-compress-root-cause-analysis-into-minutes/>
- [6] Y. Wang, C. Liu, J. Zhang, L. Zhang, et al., “VeriPilot: An LLM-powered Verilog debugging framework,” arXiv:2606.23759, 2026.
- [7] N. Wang, B. Yao, J. Zhou, Y. Hu, et al., “VeriDebug: A unified LLM for Verilog debugging via contrastive embedding and guided correction,” arXiv:2504.19099, 2025.
- [8] Y.-D. Tsai, M. Liu, and H. Ren, “RTLFixer: Automatically fixing RTL syntax errors with large language models,” arXiv:2311.16543, 2023.
- [9] S. Li, W. Fu, Y. Zhao, X. Guo, and Y. Jin, “Fixbench-RTL: A comprehensive benchmark for evaluating LLMs on RTL debugging,” in Proc. IEEE AsianHOST, 2025, pp. 1–6.
- [10] “HDL-FixBench: A repository-scale RTL repair benchmark,” OpenReview preprint, 2026. [Online]. Available: <https://openreview.net/forum?id=omi6IH5N42>
- [11] W. Fang, M. Li, M. Li, Z. Yan, S. Liu, et al., “AssertLLM: Generating and evaluating hardware verification assertions from design specifications via multi-LLMs,” arXiv:2402.00386, 2024 (ASPAC 2025).
- [12] Y. Wu, W. Fang, J. Wang, W. Li, et al., “AssertLLM2: A comprehensive LLM benchmark for assertion generation from design specifications,” arXiv:2605.27472, 2026.
- [13] H. Lyu, Y. Wang, Y. Du, M. Shi, et al., “AssertGen: Enhancement of LLM-aided assertion generation through cross-layer signal bridging,” arXiv:2509.23674, 2025.
- [14] “LASSO: Safety property generation with vacuity checking and coverage feedback,” MLCAD 2025. [Online]. Available: <https://faculty.eng.ufl.edu/sandip/wp-content/uploads/sites/681/2026/02/mlcad25.pdf>
- [15] Z. Fang, R. Chen, Z. Yang, and Y. Guo, “LintLLM: An open-source Verilog linting framework based on large language models,” arXiv:2502.10815, 2025 (GLSVLSI 2025).
- [16] J. Kim, J. Byun, D. Hwang, S.-J. Park, and H. O. Song, “Rule2DRC: Benchmarking LLM agents for DRC script synthesis with execution-guided test generation,” arXiv:2605.15669, 2026 (ICML 2026).
- [17] P. Liu, N. Xu, J. Tang, Y. Cao, and C. Ding, “Bridging the last mile of circuit design: PostEDA-Bench, a hierarchical benchmark for PPA convergence,” arXiv:2605.06936, 2026.
- [18] J. Wang, L. J. Wan, S. Pingali, S. Smith, M. Jha, et al., “OpenRTLSet: A fully open-source dataset for large language model-based Verilog module design,” arXiv:2606.10285, 2026.
- [19] P. Shrestha, A. Aversa, and I. Savidis, “EDA-Schema-V2: A multimodal schema, open datasets, and benchmarks for machine learning in digital physical design,” arXiv:2605.06952, 2026.
- [20] L. Li, X. Yu, J. Ni, J. Zhu, J. Zhang, et al., “ChipLingo: A systematic training framework for large language models in EDA,” arXiv:2604.27415, 2026.
- [21] C. Wolf, “Yosys open synthesis suite,” 2013. [Online]. Available: <https://yosyshq.net/yosys/>
- [22] C. Wolf, “SymbiYosys (sby): A front-end for Yosys-based formal verification flows,” 2018. [Online]. Available: <https://github.com/YosysHQ/SymbiYosys>