

PreCex: 反例驱动的综合前 RTL 缺陷定位与修复

佟亚龙

摘要—跨周期行为缺陷——弱测试平台仿真通过而形式验证失败的寄存器传输级 (RTL) 缺陷——是综合前最难定位与修复的问题之一。本文提出 PreCex, 一个完全开源、反例驱动的 RTL 缺陷定位与修复流水线 (iverilog/Yosys/SymbiYosys/Z3 加大语言模型, LLM)。它将失败的形式化反例转换为结构化证据, 定位缺陷区域, 生成最小补丁, 并在 golden-first 的有界模型检验 (BMC) 下重新验证。

在覆盖 6 个模块、7 类错误的 34 样本 L3 基准上 (DeepSeek v4-flash, 无泄漏三-seed 306 次), 本文以受控实验回答两个问题: 反例证据表征如何影响 RTL 缺陷定位与修复, 以及自动修复评测的可靠性如何被数据卫生与判据卫生决定。统一 BMC 判据下, 四种证据表征的 BMC 回归通过率均达 100% (操作定义: 候选补丁在有限深度 BMC 下未产生新反例); 定位精度为原始日志 (A) 64.7%、反例语义化 (C) 59.8%、因果图 (D) 56.9% 与结构化证据 (B) 55.9%, 配对检验均不显著——证据表征的定位优势被模型、数据卫生与反例时长共同调节, 而非固有属性; 深时序子集上排序反转 (s39–s42: C 75.0% > A 66.7% > D 58.3% > B 41.7%, n=12/设置; 全量 n=15/设置方向一致)。成本最低的是 D (0.37 美元/102 次), B 次之 (0.40 美元), A 最高 (0.60 美元)。变异分析杀死 88.5% 的强变异体与 81.8% 的常量变异体; 独立 T2 审计 306/306 全部通过, 接口变更与断言篡改均为零。本文进一步报告一项数据卫生教训: 初版实验存在三处 ground-truth 泄漏 (注入行号与描述进入 prompt/证据), 导致 “B 显著最优” 的伪结论; 剥离泄漏后 68 处定位结果翻转、结论反转。判据翻案审计表明, prove/k-归纳在有门控时序断言的模块上会误判 78 个正确修复, 这促使我们采用 golden-first 的 BMC 判据。L2 门禁对照 (24 样本, 72 次) 显示 BMC 回归通过率为 91.7% (系统把绝大多数单周期错误当作 L3 修复到三通过), 弱 tb 门禁不构成能力分界。

Index Terms—RTL 调试, 形式验证, 反例, 大语言模型修复, 变异分析

摘要—Cross-cycle behavioral defects – register-transfer level (RTL) bugs that pass weak testbench simulation yet fail formal verification – are among the hardest problems to localize and repair before synthesis. This paper presents PreCex, a fully open-source, counterexample-driven RTL bug localization and repair pipeline (iverilog/Yosys/SymbiYosys/Z3 with a large language

model, LLM). It converts failing formal counterexamples into structured evidence, localizes the defective region, generates a minimal patch, and re-verifies under bounded model checking (BMC) with a golden-first rule.

On a 34-sample L3 benchmark covering 6 modules and 7 error classes, we run a controlled three-seed ablation (306 leak-free DeepSeek v4-flash runs) to answer two questions: how evidence representation affects RTL bug localization and repair, and how the reliability of automated-repair evaluation is determined by data hygiene and criterion hygiene. Under a unified BMC criterion, all four evidence representations reach a 100% BMC regression pass rate (operational definition: the candidate patch induces no new counterexample within the finite BMC depth); localization accuracy is raw logs (A) 64.7%, semanticized counterexamples (C) 59.8%, causal graphs (D) 56.9%, and structured evidence (B) 55.9%, with no significant paired differences (A/B/C) – the localization advantage of evidence representation is jointly moderated by model, data hygiene, and counterexample length rather than being intrinsic (the ordering reverses on a deep-timing subset (s39–s42: C 75.0% > A 66.7% > D 58.3% > B 41.7%, n=12 per setting; consistent direction on the full n=15 per setting)). Cost is lowest for D (\$0.37 per 102 runs), followed by B (\$0.40) and A (\$0.60). Mutation analysis kills 88.5% of strong mutants and 81.8% of constant mutants; an independent T2 audit passes 306/306 with zero interface changes or assertion tampering. We further report a data-hygiene lesson: the initial experiment contained three ground-truth leaks (injected line numbers and descriptions entering prompts/evidence), which produced a false “B significantly best” conclusion; after removing the leaks, 68 localization outcomes flipped and the conclusion reversed. A criterion-reversal audit shows that prove/k-induction misjudges 78 correct repairs on modules with gated temporal assertions, motivating the golden-first BMC criterion as a methodological lesson for automated-repair evaluation. An L2 gate control (24 samples, 72 runs) reports a BMC regression pass rate of 91.7% – the system repairs most single-cycle bugs to three-pass status, so the weak-testbench gate is not a capability boundary.

Index Terms—RTL debugging, formal verification, coun-

I. 引言

A. 背景与问题

寄存器传输级（RTL）设计复杂度持续增长，跨周期行为缺陷（L3：弱测试平台通过而形式验证失败）是综合前最难定位与修复的缺陷类型之一。此类缺陷通常隐藏在状态机迁移、握手时序或边界回绕逻辑中：简单断言行启发式无法命中注入点，仿真波形中的信息过载使人工与自动化定位都极为耗时。一旦缺陷进入综合与流片流程，修复成本呈数量级上升，因此在综合前准确、低成本地定位并修复 RTL 缺陷具有明确工程价值。

需要精确界定本文的适用边界：PreCex 主要针对失效轨迹较短（本基准中位 6 拍）、可通过局部代码修正恢复的 L3 缺陷子集；对于长周期状态机死锁、多周期握手超时等需要结构性重写的缺陷，本系统生成的候选补丁虽能通过有限深度 BMC 回归，但属于工程上的绕过方案，完整修复留待未来工作（见 §VI-A）。

现有基于大语言模型（LLM）的修复流水线主要面临两类困难。其一，直接输入原始日志或波形，信息过载导致定位噪声，模型难以从数千行仿真记录中筛出真正的因果信号。其二，依赖参考模型（golden reference model）进行差分调试的方法在综合前阶段往往不可用——此时不存在可作为规范的金牌实现。近期工作（FVDebug、GROVE）证明了结构化反例理解的价值，但仍缺乏四点能力：（1）开源端到端流水线；（2）面向跨周期缺陷的系统性研究；（3）严格的验证充分性闭环；（4）证据表征的受控消融。

B. 设计动机

本文观察到，传递给 LLM 的证据表征（evidence representation）是一个关键但缺乏研究的维度：同样的模型能力下，证据如何组织直接决定定位精度与 token 成本。为此，我们在同一 34 样本 L3 数据集上，用 DeepSeek v4-flash 对三种证据表征做三-seed 严格配对的受控消融（A/B/C，306 次无泄漏运行，见 §IV）：A 为原始反例日志与 VCD 头尾；B 为结构化证据（EvidenceEngine JSON）；C 为反例语义化（CexSemantizer 输出的周期事件、状态轨迹、故障锥与自然语言摘要）；D 为 FVDebug 式因果图（确定性提取），作为探索性设置复跑。初版实验曾因三处 ground-truth 泄漏（§V-G）得到“B 显著

最优”的伪结论，剥离泄漏后结论反转，这本身成为本文的评测卫生教训。

与此同时，本文强调修复判据本身必须接受检验：原协议采用 prove/k-归纳判据，但对带门控时序断言的 axi/uart 模块不收敛——golden 设计本身即返回 UNKNOWN，导致 78 个正确修复被误判为失败。据此我们确立了 **golden-first 规则**：任何修复判据必须首先在 golden 设计上通过，才可用于评判修复结果。

C. 贡献

本文的主要贡献如下：

- **开源反例驱动修复流水线与评测资产**：基于 iverilog/Yosys/SymbiYosys/Z3 与 DeepSeek v4-flash 的端到端实现，完全可复现；配套 34 样本 L3 数据集，含 golden 双重校验、ground-truth 隔离审计与充分性审计（变异/空泛/T2/delta-debugging）。
- **干净口径的证据表征消融（探索性结论）**：统一 BMC 判据下三种设置 BMC 回归通过率均达 100%；定位精度 A 64.7% > C 59.8% > B 55.9%，配对检验均不显著——证据表征的定位优势被模型与数据卫生强烈调节，而非固有属性；成本 B 最低（0.40 vs A 0.60 美元）。
- **评测双卫生方法论教训**：ground-truth 泄漏（三处）会使“B 显著最优”成为伪结论（剥离后 68 处定位翻转、结论反转）；prove/k-归纳判据失效会误判 78 个正确修复。数据卫生（ground-truth 隔离）与判据卫生（golden-first）是自动修复评测的可靠基准。

II. 相关工作

A. 反例驱动的调试与根因分析

FVDebug (Bai 等, 2025) [1] 是最接近的同类工作：它从失败的形式化轨迹构建因果 DAG，用批量 LLM 调用扫描可疑节点，通过 agent 生成根因叙述并输出修复，在两个工业反例上完成演示。PreCex 与其共享反例理解这一核心：我们的设置 D 是 FVDebug 式因果图的确定性开源实现（失败断言、故障锥、全周期状态轨迹与触发条件）。FVDebug 在三个维度上留有空缺，而 PreCex 恰好控制：其一，它依赖商业工具链；其二，它没有报告证据表征的受控消融；其三，它不量化验证器充分性。PreCex 完全开源（iverilog/Yosys/SymbiYosys/Z3），在同

一 34 样本数据集上比较四种证据表征, 并以变异分析、空泛性控制与独立 T2 审计评测验证器。

GROVE (Bai 与 Ren, 2025) [2] 将断言失败调试知识组织为分层知识树: 训练时以模型检验验证知识项, 测试时按预算感知检索, 一致提升 $\text{pass}@1/\text{pass}@5$ 。GROVE 与 PreCex 互补: GROVE 跨样本积累可复用知识, PreCex 消费单个失败反例, 在无历史存储的闭环中完成定位-修复-重验。GROVE 式知识层可作为本流水线的自然扩展。

开源 LLM 驱动形式验证 (Tran, 2026) [3] 采用与本文相同的开源工具链 (Yosys/SymbiYosys/Z3), 以 LLM 引导反例驱动迭代修复, 以 k-归纳证明或预算耗尽为停止条件, 在 6 个基准上仅可靠修复 1 个。该工作验证了开源管线的可行性并整理了失败模式; PreCex 的差异在于增加证据语义化层 (该工作将原始反例直接送入 LLM), 并在更大、受控的 L3 数据集上采用 golden-first 判据。

FormalRTL [4] 以软件参考模型作为形式化规范, 闭合规划、综合与等价检验循环, 并含一个反例简化器, 只高亮失败功能与不匹配信号。PreCex 不作参考模型假设: 仅凭断言与反例工作, 这正是综合前无黄金模型时的常见设置。

ChipAgents RCA (商业, 2026) [5] 将波形理解引擎与 prover-verifier agent 对及自一致性排序结合, 报告了工业部署中对三周期竞争条件的定位。它佐证跨周期根因分析是真实工业痛点, 但作为闭源黑盒, 未提供任何消融细节。

B. 基于 LLM 的 RTL 修复

VeriPilot [6] 使用黄金参考模型与 CDFG 信号追踪, 将 CVDP 上的 GPT-4o 修复率从 54.3% 提升至 85.71%。**VeriDebug** [7] 学习对比嵌入并引导修正, 在定位加类型联合任务上取得 64.7% 的 $\text{Acc}@1$ 。**RTLFixer** [8] 采用检索增强修复语法错误。三者均非反例驱动: 分别依赖参考模型、微调嵌入或仅做语法级修复。PreCex 明确针对综合前无参考模型的场景, 将证据表征而非模型能力作为研究变量。

Fixbench-RTL [9] 与 **HDL-FixBench** [10] 是修复基准: Fixbench-RTL 覆盖语法、功能与安全域; HDL-FixBench 面向仓库级实例 (OpenTitan/CVA6/Ibex 共 57 个实例, 最佳模型 40.3%, 被 ICLR 2026 拒稿)。HDL-FixBench 被拒稿所暴露的缺陷正是 BugBench-PS 着力

表 I

设计空间定位: 与已有工作的证据表征、开源性与评测闭环对比

工作	证据表征	开源	跨周期	消融	充分性
FVDebug	因果图	否	部分	否	否
GROVE	知识树	否	否	否	否
Tran 2026	原始反例	是	部分	否	否
FormalRTL	反例简化 + 参考模型	部分	否	否	否
VeriPilot	CDFG+ 参考模型	否	否	否	否
VeriDebug	学习嵌入	否	否	否	否
AssertLLM2	断言生成	—	—	—	变异驱动
PreCex	原始/结构化/语义化/因果图	是	34 样本	A/B/C/D	变异/空泛/T2

规避的: 规模过小、多样性不足、补丁阈值存在争议、缺少非 LLM 基线以及数据污染风险。

C. 断言生成与验证充分性

AssertLLM [11] 与 **AssertLLM2** [12] 从自然语言规格加波形生成 SVA 断言; AssertLLM2 引入 83 设计的断言基准, 并以变异驱动的 bug-hunting 设置评测断言。**AssertGen** [13] 通过思维链提取验证目标并桥接跨层信号, 采用变异测试覆盖率评估。**LASSO** [14] 生成带显式空泛性检查与覆盖反馈的安全属性, 在 OpenTitan 中发现 5 个真实缺陷。**LintLLM** [15] 以变异缺陷注入执行 LLM 代码检查。

这些工作生成或审计断言; PreCex 消费断言加反例以完成定位与修复。其评测实践 (变异覆盖、空泛性、bug-hunting) 构成了本文充分性审计的方法学先例: 88.5% 强变异与 81.8% 常量变异被杀, 删除变异空泛性控制通过。

D. 基准与评测方法

工具执行裁决 (tool-execution adjudication) 是 EDA-AI 领域公认的评测实践: Rule2DRC [16] (ICML 2026) 比较 13,921 条布局规则结果, PostEDA-Bench [17] 评估 145 个 DRC/PPA 任务, 均通过执行设计工具裁决。PreCex 遵循同一原则: 修复成功由编译、弱测试平台回归与形式 BMC 裁决, 从不依赖 LLM 自述。工程语义数据集 (OpenRTLSet [18]、EDA-Schema-V2 [19]、ChipLingo [20]) 为本文证据模式设计提供参考。

E. 本文定位

表 I 汇总了与已有工作的定位差异。PreCex 的三项差异化能力均有受控实验佐证: (1) 完全开源、可复

现的反例驱动流水线：(2) 四设置证据表征消融与配对显著性检验；(3) 带验证充分性闭环（变异、空泛、独立 T2 审计）的跨周期 L3 基准。此外，判据翻案审计（第 V-F 节）贡献了一条方法论经验：修复判据必须先用 *golden* 设计验证，才能用于评判修复。

III. 方法

系统版本口径：第 III 节描述的完整系统包含若干增量机制（历史修复记忆、*delta-debugging*、自适应窗口与工具链预检），其中部分机制在投稿时已实现但尚未完成全量重跑；主实验（第 IV–V 节）基于一个功能子集（无历史修复记忆、固定窗口 8、无 *delta-debugging*），该子集足以支撑本文的证据表征消融研究。增量机制与主实验结论的兼容性由深时序子集小规模实测佐证（第 V-I 节，s38–s42 四设置 60/60 全部完成），完整系统的更大规模全量评测留待后续工作。

A. 系统架构




图 1. PreCex 流水线：失败的形式化反例经解析生成结构化证据（B），可选语义化（C）或汇总为因果图（D），由 LLM 修复器生成最小 diff，并在 *golden-first* 的 BMC 判据下重新验证；失败结果回灌循环。

整体架构如图 1 所示。PreCex 由四个核心组件与两个支撑元素构成（开源工具链 *iverilog*、*Yosys* [21] 与 *SymbiYosys* [22]）。**EvidenceEngine** 将 *cex.log* 解析为统一 JSON 结构（错误类型、模块、文件、行号、代码片段、信号、触发条件、失败阶段与失败步）。**CexSemantizer** 将 VCD 转换为周期事件表、状态轨迹、故障锥与自然语言摘要（*window=8* 压缩）。**LocalRepairer** 以设计、断言与证据为输入（*DeepSeek v4-flash*, *temperature 0.2*），输出定位与最小统一 diff，重试不超过两轮；每次失败尝试的 diff 与失败原因被注入下一轮 prompt（历史修复记忆，见 §III-F），明确要求 LLM 分析上次为何失败并避免重复该模式，避免“开环重试”重复同一错误补丁。**Verifier** 执行三关验证：*iverilog* 编译零

错误、弱测试平台仿真全绿、*sby smtbmc+z3 BMC* 无反例（主判据），并叠加 *golden* 双重校验；工具链适配由断言安全子集（*Gate-1* 收敛）与前置兼容性预检（*scripts/check_rtl_compat.py*，见 §III-H）保障，工具解析失败按 *INCONCLUSIVE* 记录而非崩溃。支撑元素为实验变量控制组件与 *BugBench-PS* 数据集资产。

B. 证据引擎与反例语义化

EvidenceEngine 以失败断言、错误类型与失败阶段的统一模式组织反例，输出稳定可解析的 *evidence.json*。**CexSemantizer** 在此基础上生成周期事件表（每周信号变化）、状态轨迹（跨周期信号演化）、故障锥与自然语言摘要。故障锥的算法为静态代码级扇入：取失败断言表达式（*trigger_condition*）、失败行 ± 4 行代码切片（*code_slice*）与关键控制/状态/协议信号（按模块时钟域枚举的 *KEY_SIGS*）三者并集，再过滤参数/内部辅助前缀（*DATA_/OP_/f_* 等）。它不依赖 VCD 中信号是否翻转——恒定错误值的根因信号仍经断言表达式/代码切片进入锥——但代价是可能包含与缺陷无关的周边信号，该边界在 §VI-A 如实声明。实验表明主数据集反例普遍较短（VCD 时钟事件合计 295 拍，中位 6 拍，最长 41 拍），*window=8* 窗口压缩的收益有限——语义化的成本由摘要文本主导而非轨迹长度，这一观察直接支撑了第 V-D 节的成本分析。需要指出，固定 *window=8* 会截断长反例的关键因果尾部：最长样本 41 拍，而 8 拍之后的窗口在状态机死锁/握手超时类缺陷上可能正是根因所在，属系统性信息损失而非成本权衡。为此 **CexSemantizer** 提供失败时刻尾部回溯的自适应窗口（ $\text{window_eff} = \max(8, \min(24, \lfloor \text{fail_step}/2 \rfloor))$ ），深时序子集（35–75 拍，仓库 *samples/deep*）的语义化已采用该策略；主数据集 34 样本为口径一致仍保留 *window=8*，该截断作为本版本的系统性局限列入 §VI-A。

C. 四种证据表征

各设置的证据内容与提取成本见表 II。四种设置使用同一 prompt 家族，仅替换证据段，以控制偏置。A 为基线，B 与 D 均为零 LLM 成本的确定性提取，C 引入一次 LLM 语义化调用，是四者中唯一的额外推理成本来源。

D. 修复判据：*golden-first* 规则

主判据为 BMC（*verify.sby*），与 *golden* 验证（*verify_golden.sby*）一致。原协议采用 *prove/k*-归纳

表 II
四种证据表征设置（受控消融）

设置	证据	提取方式	单次成本
A	原始 cex.log + VCD 头尾	无	基线
B	evidence.json（结构化）	确定性	低
C	semantics.json（周期事件 + 状态轨迹 + 故障锥 + 摘要, window=8）	LLM 语义化	高
D	FVDebug 式因果图（失败断言 + 故障锥 + 全周期状态轨迹 + 触发条件）	确定性（零 LLM）	最低

（verify_repair.sby）作为修复判定，但在带门控时序断言的 axi/uart 模块上不收敛：golden 设计本身返回 UNKNOWN（rc=4），旧判据下 78 个正确修复被误判为失败。同一正确修复（s33 的 B 设置 seed0、s17 的 B 设置 seed1）在 bmc 下 PASS、prove 下 FAIL 的实测直接暴露了这一矛盾。

据此确立 golden-first 规则：任何修复判据必须首先在 golden 设计上通过（判据-黄金一致性检查），方可用于评判修复。对 A/B/C 306 次运行中含修复 diff 的 303 条按 BMC 判据重验，303/303 全部通过（其余 3 条网络失败补跑亦通过），旧 prove 判据下 BMC 回归通过率仅 74.3%，修正为 BMC 判据下的 100%。prove/k-归纳仅作为辅助参考保留，不再作为失败判据。

E. 验证充分性审计

为量化断言集能否捕获注入缺陷（充分性），本文对 golden 设计执行三类变异：

- **强变异**：比较器反转等强语义变异（d16），400 个变异体，88.5% 被杀。
- **常量变异**：替换参数常量 DATA_W/ADDR_W/DEPTH/DIV/HALF，484 个变异体，81.8% 被杀。
- **删除变异**：移除断言，作为空泛性控制，全部通过（若删除断言后仍能杀变异，说明断言冗余）。

模块级分析显示 axi 与 fifo 的强变异杀死率为 100%，而 uart_rx 最弱（强变异 55.0%、常量变异 40.9%）——结构断言对波特时序常量漂移不敏感，这是已记录的局限并列为未来工作。此外，T2 审计以确定性脚本替代 LLM 自证，对全部含 diff 的修复（A/B/C 306 条 + D 102 条）检查三类违规：接口/端口/参数变更、断言篡改、证据闭环一致性，均零失败；loc_dev 中位数为 0（干净口径 A/B/C 51.3% 精确命中），补丁规模均值 2.1 行、最

大值 6 行。补丁“最小性”并非仅由规模数字佐证：新增后验 delta-debugging 检查（scripts/minimize_patch.py，见 §III-G）对通过修复迭代移除 diff 中的改动单元，仅当移除后仍通过编译/仿真/BMC 三通过才保留，直至 1-minimal；在深时序子集真实修复上实测确认无冗余单元（移除任一单元即 FAIL，见 §III-G）。

F. 反馈循环与历史修复记忆

LocalRepairer 的重试并非“开环重试”：每次失败尝试的 diff 与失败原因（编译错误/仿真 FAIL/BMC 反例）被写入历史记录，并注入下一轮 prompt——prompt 显式给出“上次 diff + 失败原因 + 请避免该模式”的指令，要求 LLM 先分析上次修复为何失败再给出不同方案。该机制在实现层面已落地（scripts/run_experiments.py 的 retry_history），首次尝试的 prompt 与冻结协议逐字节一致，因此不影响已报告数字。需要诚实说明：干净口径主实验（306 次）与 L2 对照（72 次）均运行于固定 prompt 协议（重试仅重复同一 prompt），报告的重试统计（DeepSeek attempts=1.02）反映的是该协议下的行为；历史修复记忆是当前代码新增机制，面向后续扩展子集生效，用于消除“闭环承诺与开环实现”的落差。

G. 最小补丁后验验证（delta-debugging）

“最小统一 diff”若不经过后验验证，只是对 LLM 提示词中“最小”二字的信任。为此新增确定性 delta-debugging 组件（scripts/minimize_patch.py）：把通过三通过的修复 diff 拆成改动单元（每个 hunk 内连续的 -/+ 行块），贪心迭代尝试移除单元，仅当移除后仍通过编译/仿真/BMC 三通过才保留，直至 1-minimal。深时序子集真实修复实测：s40（fifo 满时仍写）修复 diff 为 1 单元，移除该单元后验证 FAIL，确认修复必要且无冗余改动；合成双单元用例（真实修复 + 注释级冗余 hunk）被正确约减到真实修复。诚实边界：1-minimal 是相对当前验证判据的，单行补丁仍可能是弱修复（例如引入冗余条件绕过触发路径）；delta-debugging 与 T2 审计（接口/断言不变）只约束该风险、不能根除，这属于“候选补丁生成器”定位的固有边界（见 §VI-A）。

H. 工具链适配层

系统对 Yosys/SymbiYosys 工具链的解析失败采用“预防 + 降级”两层设计：其一，断言安全子集（Gate-1 实测收敛）限定 immediate assert/assume、if 门控、打拍跨周

期等结构，从源头避免并发 SVA (assert property、\$past、|>、##n) 等 Yosys/iverilog 不支持的结构进入形式验证；其二，前置兼容性预检 (scripts/check_rtl_compat.py) 在 LLM 调用前扫描设计/断言文件中的不兼容结构 (并发 SVA、real 类型等)，fail-fast 给出可操作改写建议，替代“运行中才崩溃”。验证阶段，工具超时/解析错误由 evaluator 归类为 INCONCLUSIVE 并记录 (不中断流水线)，与 golden-first 规则共同构成降级路径；主协议中证明/k-归纳对门控断言返回 UNKNOWN 的问题即由此路径处理 (见 §V-F)。

IV. 实验设置

A. 数据集 BugBench-PS

BugBench-PS 包含 34 个 L3 样本 (s04–s37)，覆盖 6 个开源教学级模块：fifo_sync、uart_tx、uart_rx、axi_lite_slave、fsm_ctrl 与 counter_alu，错误类别共 7 类：状态迁移 (24 样本)、握手 (12 样本)、复位 (18 样本)、FIFO 满空 (15 样本)、边界回绕 (21 样本)、位宽截断 (9 样本) 与边沿 (3 样本)，合计每设置 102 条定位记录。每个样本经 golden 双重校验 (buggy 设计在 BMC 下 FAIL，golden 设计 PASS)，并通过唯一性/结构审计 (34/34 通过)。断言行、信号行与随机行启发式基线全部失败 (0% 或 0.50% 期望)，证明注入缺陷位于功能/时序逻辑而非断言块。

B. 评测协议与成本记账

主实验为干净口径下的 34 样本 $\times$ 3 设置 (A/B/C) $\times$ 3 seeds = 306 次真实 LLM 修复运行 (DeepSeek v4-flash, temperature 0.2, OpenAI 兼容端点)。初版实验以 MiniMax M3 在四设置上运行 408 次，但审计发现三处 ground-truth 泄漏 (见 §V-G)，其数字整体作废，仅作为卫生教训的对照引用；本文所有结论基于无泄漏重跑。修复成功由 BMC 加 golden 双重校验裁决。成本按 API token 记账 (DeepSeek v4-flash 公开单价：输入 0.14 美元/百万 token、输出 0.28 美元/百万 token，为估算值而非平台账单)，干净主实验合计 1.57 美元 (306 次运行，平均 0.0051 美元/次，分设置 A 0.60/B 0.40/C 0.57 美元)。L2 门禁对照使用 24 个 L2 样本 $\times$ A/B/C (72 次调用，见 §V-E)；D 设置 (因果图) 以同协议复跑完成 (102 次调用，成本 \$0.37，定位 56.9%)。运行采用并行调度：8 并发、420 秒硬超时与断点续跑。

C. 可复现性

全部实验基于开源工具链：iverilog 12.0、verilator 5.020、yosys 0.33、SymbiYosys (sby, smtbmc+z3 引擎) 与 Python 3.12，运行于 WSL。证据链生成命令为 `python3 scripts/build_evidence.py --samples s04-s37 --real --window 8`；干净主实验 (306 条)、L2 对照 (72 条) 与 D 复跑 (102 条) 均经 `scripts/run_experiments.py --provider deepseek` 执行，结果分别落盘到 `experiments/runs/leakfix_0..7.json`、`leakfix_l2.json` 与 `leakfix_D_0..7.json`；充分性量化、T2 审计与 BMC 重验分别由 `verify_sufficiency.py`、`t2_audit.py`、`reverify_bmc.py` 完成。所有 LLM 调用强制写入 token 账本 (`experiments/runs/token_ledger.jsonl`)，成本按输入 $\times$ 输入单价 + 输出 $\times$ 输出单价线性估算 (DeepSeek v4-flash: 0.14/0.28 美元每百万 token，标注为估算口径)。数据集 BugBench-PS (34 样本，6 模块 $\times$ 7 错误类型) 与复现命令链一并开源，见仓库 REPRO.md。

D. 非 LLM 基线

为确立 LLM 定位的非平凡性，在相同精确匹配口径 (候选行等于 `buggy_inject_line`，34 样本) 下评测三类简单启发式：首个断言行、任意断言行、首个提及失败信号的证据行，以及随机行期望。结果全部为 0% (随机行期望 0.50%)；干净口径下 DeepSeek v4-flash 三设置的定位精度 55.9–64.7% 远超这些基线，最高的 A (64.7%) 约为随机期望的 129 倍。注意：旧泄漏版曾以 MiniMax 的 47.1–61.8% 作此比较，该数字已被卫生审计作废。

V. 实验结果与分析

A. 结果概览

表 III 与图 2 汇总了四设置的主实验结果。发现 1：统一 BMC 判据下，干净口径四种证据表征的 BMC 回归通过率均达 100%——证据表征不决定能否修复，而决定多准、多便宜。

发现 2：在干净口径 (DeepSeek v4-flash，无泄漏) 下，定位精度排序为原始日志 (A) 64.7% (Wilson 95% CI 55.1–73.3) > 反例语义化 (C) 59.8% (50.1–68.8) > 因果图 (D) 56.9% (47.2–66.1) > 结构化证据 (B) 55.9%

表 III

四设置干净主实验结果 (DeepSeek v4-FLASH, $n=102$ 每设置; BMC 回归通过率按有限深度 BMC 判据)

设置	n	定位 Top-1	BMC 通 过率	Tokens	成本 (USD)
A 原始日志 & 102 & 64.7% & 100% & 2.486M & 0.60					
B 结构化证据 & 102 & 55.9% & 100% & 1.672M & 0.40					
C 反例语义化 & 102 & 59.8% & 100% & 2.503M & 0.57					
D 因果图 & 102 & 56.9% & 100% & 1.601M & 0.37					




图 2. 各设置的定位 Top-1 精度 (柱) 与 LLM 成本 (折线)。四设置均为干净口径 (DeepSeek v4-flash); 全部六对差异均不显著 (配对 McNemar 精确检验, Holm 校正后 $p > 0.05$)。

(46.2–65.1); 成本上 D 最低 (0.37 美元/102 次), B 次之 (0.40 美元), A 最高 (0.60 美元), 呈现与旧泄漏版相反的精度/成本权衡。

统计显著性 (干净口径) : 对 102 条逐样本定位结果按 (样本, seed) 配对做 McNemar 精确检验, 报告全部六对对比并经 Holm 校正: A 对 B $p = 0.078$ (率差 +8.8 pp, 95% CI $[-4.6, +22.2]$)、A 对 C $p = 0.227$ (+4.9 pp, $[-8.4, +18.2]$)、A 对 D $p = 0.096$ (+7.8 pp, $[-5.5, +21.2]$)、B 对 C $p = 0.455$ (-3.9 pp, $[-17.5, +9.6]$)、B 对 D $p = 1.000$ (-1.0 pp, $[-14.6, +12.6]$)、C 对 D $p = 0.664$ (+2.9 pp, $[-10.6, +16.5]$)——六对 Holm 校正后均不显著 ($p_{\text{holm}} \geq$

表 IV

错误类别 $\times$ 设置定位精度 (每设置 n : 状态迁移 24、握手 12、复位 18、FIFO 满空 15、边界回绕 21、位宽截断 9、边沿 3)

错误类别	A	B	C	D
状态迁移	37.5%	25.0%	29.2%	29.2%
握手	50.0%	41.7%	50.0%	41.7%
复位	77.8%	88.9%	83.3%	61.1%
FIFO 满空	53.3%	53.3%	60.0%	53.3%
边界回绕	81.0%	71.4%	76.2%	76.2%
位宽截断	100%	55.6%	66.7%	88.9%
边沿	100%	66.7%	66.7%	100%

0.470), 且全部率差 95% 置信区间跨越 0, 效应量不足以支撑任何最优设置声明。旧泄漏版报告的 B 对 A $p = 0.0035$ 显著结论已被推翻。seed 独立性方面, 推理使用 temperature=0.2 且 prompt 携带 seed 标识 (§IV), 聚合定位率跨 seed 波动为: A 0.0 pp (三 seed 均为 64.7%, 但逐样本存在 5/34 处跨 seed 翻转)、C 与 D 各 2.9 pp、B 11.8 pp (50.0%–61.8%), 说明三-seed 配对提供了真实而非名义的抽样方差, 其中 B 设置的噪声最大。全部对比均报告, 包括不显著项。

B. 错误类型分析




图 3. 错误类别 $\times$ 设置的定位 Top-1 精度热力图。困难类别排序 (状态迁移/握手低于位宽截断/边沿) 在全部设置中成立。

图 3 与表 IV 给出按错误类别分解的定位精度。发现 3: 单点语义错误易定位 (位宽截断 A 100%、边沿 A 100%), 跨状态与握手错误难定位 (状态迁移 30.6%、握手 47.2%, $n=72/36$), 该难度排序在全部设置中成立。干净口径下, A (原始日志) 在数值/位宽/边界类上表现最强 (位宽截断 100%、边界回绕 81.0%), B 仅在复位类上最高 (88.9%) ——与旧泄漏版 “B 在边界回绕/位

表 V
变异分析充分性（针对 GOLDEN 设计）

变异家族	变异体	被杀	比率
强变异（比较器反转）	400	354	88.5%
常量变异（参数常量替换）	484	396	81.8%
删除变异（断言移除）	抽样	全部 PASS	空泛性控制

宽截断最优”的结论相反（握手/边沿类每设置 $n \leq 12$ ，小样本需谨慎解读）。

C. 修复可信度：充分性与 T2 审计

变异分析结果见表 V。T2 确定性审计对干净口径 306/306 条修复全部通过：接口变更 0、断言篡改 0、证据闭环失败 0；loc_dev 中位数 0（A/B/C 51.3% 精确）。补丁最小化由均值 2.1 行、最大值 6 行佐证。

D. 成本与性能

四设置干净主实验总成本 1.94 美元（408 次运行，平均 0.0048 美元/次）；分设置为 A 0.60、B 0.40、C 0.57、D 0.37 美元，token 分别为 2.486M、1.672M、2.503M、1.601M。C 的成本来自语义化摘要文本而非轨迹长度：主数据集反例中位 6 拍（VCD 时钟事件合计 295 拍、最长 41 拍），轨迹较短，窗口压缩收益有限。验证性能方面，BMC 重验与深度敏感性抽查（见 §V-F）按样本并行调度（8 并发）；单样本 golden 验证耗时以 axi 约 88 秒、uart_rx 约 153 秒为上限。

E. L2 门禁对照：假阳性率

为量化数据集纯度门禁（弱测试平台可观测）对系统能力的区分度，我们构造 24 个 L2 样本（单周期功能错误，弱 tb FAIL + formal fail 双检通过，覆盖 axi/counter/fifo/fsm/uart_rx/uart_tx 六模块），并以与主实验相同的无泄漏协议用 DeepSeek v4-flash 在 A/B/C 三设置下各评测一次（72 次调用，成本 \$0.48）。结果：L2 的 BMC 回归通过率为 91.7%（66/72），与旧泄漏版数值相同但已由无泄漏协议复现——该通过率是稳定现象而非泄漏伪影；它与 L3 基线（100%）仍差 8.3 个百分点——弱 tb 门禁不构成系统能力的显著分界，系统能把绝大多数单周期错误当作 L3 修复到三通过。

未通过的 6 次调用全部集中在两个 L2 样本（l2_uarttx_01 起始位握手失效、l2_uarttx_02 状态跳转

至 STOP），三设置均为 INCONCLUSIVE，失败模式一致：候选补丁通过 BMC 与 golden 校验，但弱 tb 仿真回归仍未通过（formal=pass、sim 挂），是 uart_tx 协议交互类缺陷难以定位修复的又一证据。按设置看，干净口径下 L2 定位精度为 A 58.3%、C 45.8%、B 37.5%（ $n=24$ ，小样本），与 L3 上 $A > C > B$ 的排序方向一致——与旧泄漏版“B 在 L2 最高（50.0%）且与 L3 B 优势方向一致”的结论相反。该对照实验说明：证据表征的相对优势主要体现于跨周期（L3）缺陷，对单周期可观测（L2）缺陷区分度有限；论文将 L2 门禁的纯度代价如实报告：91.7% 的通过率意味着弱 tb 门禁无法按修复能力对单周期缺陷分层。

F. 判据翻案的方法论教训

发现 4：原 prove/k-归纳判据误判 78 个正确修复（golden 本身在 prove 下 UNKNOWN）。对 A/B/C 306 次运行按 BMC 判据重验（303 条含 diff 记录重验 + 3 条网络失败补跑）全部通过，BMC 回归通过率由 74.3% 修正为 100%。判据强度抽查进一步将 34 个样本的修复在 2 倍 BMC 深度下重验（fifo/uart_tx/fsm/counter 12→24、axi 16→32、uart_rx 24→48），34/34 全部通过，未发现深度敏感性翻转。这一翻案说明：修复判据必须先经 golden 一致性校验，否则判据缺陷会系统性污染修复率、定位精度与成本等全部下游指标。PreCex 将 BMC 判据与 golden-first 规则固化为评测协议的一部分，作为可复用的方法论产出。

G. 数据卫生审计

初版实验（MiniMax M3，408 次）在冻结协议审计中被发现三处 ground-truth 泄漏：（1）系统 prompt 元数据注入缺陷注入行号（inject_line）；（2）B 设置直接嵌入 evidence.json 全文，而该文件含 inject_line/inject_desc 标注；（3）buggy.v 头注释含缺陷描述与行号，进入 A/B/C 的设计代码段。据此实施两步修复：其一，冻结协议层逐字节剥离上述字段（prompt_templates.sanitize_design_text 与 run_experiments.py 的 _strip_gt，配套 scripts/audit_ground_truth.py 回归检查与单元测试）；其二，全部数字以无泄漏重跑为准（DeepSeek v4-flash，A/B/C，306 次）。重跑后 loc_top1 共 68 处翻转（旧 True→新 False 28 处、旧 False→新 True 40 处），总体定位由 56.2% 升至 60.1%，结论由“B 显著最优”反转为“三设置无显著差异、A 略高”；BMC 回归通过率

两版均为 100%，表明泄漏虚增的主要是 B 的相对定位优势与统计显著性，而非修复能力本身。该审计链路（扫描脚本、冻结协议与 token 账本）随仓库开源，供自动修复评测复用。

H. 模块与错误类型的交互效应

发现 5：定位难度并非均匀分布，而是由缺陷类型与模块共同决定（干净口径 306 次运行，BMC 判据）：协议交互类缺陷（uart_tx/uart_rx 的握手与状态迁移）在 A/B/C 三设置下 top-1 定位全部为 0%，而数值/位宽/边界类缺陷整体可定位性高（axi_lite_slave 边界回绕 83.3–100%、fifo_sync 位宽截断 A/C 100%、counter_alu 状态迁移 A/C 100%）。在干净口径下，这类”算术/位宽/边界”增益属于原始日志（A）而非结构化证据（B）——与旧泄漏版”B 增益集中在数值/位宽/边界”的结论相反，再次说明泄漏虚增了 B 的相对定位优势。对协议交互类缺陷，证据表示难以改善定位精度，但形式再验证闭环仍能保证 BMC 回归通过率 100%。D（因果图）整体定位 56.9%，仅在 counter_alu 上最高（91.7%）——确定性提取的因果图并未带来相对原始日志的增益。

I. 深时序子集：反例时长与证据表征的交互

为检验证据表征效应是否随反例时长变化，我们对 5 个深时序样本（s38–s42，反例 35–75 拍，仓库 samples/deep）以四设置 × 3 seeds 完成补测（60 次调用，成本 \$0.25）。深子集语义化采用失败时刻尾部回溯的自适应窗口（window_eff，见 §III-B），其余设置与主实验协议一致。

探索性发现：全部 60 次补测（5 样本 × 四设置 × 3 seeds）均达 BMC 回归通过（修复率 100%），其中 s38 在 C/D 设置上虽定位为 0/3（该样本本身极难），但四设置修复均成功。剔除 s38 后四样本（s39–s42，n=12/设置）定位排序为 C 75.0% > A 66.7% > D 58.3% > B 41.7%，与主数据集（A 64.7% > C 59.8% > D 56.9% > B 55.9%）发生反转；含 s38 的全量（n=15/设置）排序为 C 60.0% > A 53.3% > D 46.7% > B 33.3%，反转方向一致。该反转说明：原始日志（A）在短反例（中位 6 拍）上更有利，而语义化（C）在长反例上更有利——证据表征的相对优势随反例时长而改变，而非固定属性。需诚实声明其混杂因素：深子集的 C 设置同时采用了自适应窗口（主数据集为固定 window=8），因此语义化增益可能与窗口策略耦合；反例时长与窗口策略的单独效应留待未来消融。

表 VI

跨模型主实验对比（MiniMax M3 vs DeepSeek v4-FLASH，三-SEED 严格配对，N=102 每设置；BMC 回归通过率按有限深度 BMC 判据；MM 干净复跑待补）

设置	MM 定位	DS 定位	MM 修复	DS 修复
A 原始日志 & 待复跑 & 64.7% & 100% & 100%				
B 结构化证据 & 待复跑 & 55.9% & 100% & 100%				
C 反例语义化 & 待复跑 & 59.8% & 100% & 100%				

J. 证据可解释性的多模型评估

探索性评估：为量化 C/D 证据表示的可解释性差异，我们以 5 维 Likert 量表（完整性、可读性、因果性、可操作性、可信度，1–5 分）对 10 个样本的 C（反例语义化）与 D（FVDebug 式因果图）证据进行独立评分。**评分独立性保证：**被评的 C 证据文本由 DeepSeek v4-flash 生成（CexSemantizer, summary_meta 可查证），主实验定位与修复亦由 DeepSeek 执行；评分为 MiniMax M3 单模型独立完成（20 次调用，总成本 \$0.09）——MiniMax 不参与证据生成、不参与修复、不参与定位，为完全外部的评分者。该设计消除了”评分者与被评对象相同模型”的潜在偏倚。在此口径下，MiniMax 对 C/D 证据的五维绝对评分如下：C 证据完整性 3.33、可读性 2.33、因果性 3.11、可操作性 3.00、可信度 2.44；D 证据完整性 2.56、可读性 2.56、因果性 2.11、可操作性 2.22、可信度 2.11。MiniMax 评分显示 C（语义化）在因果性（3.11 vs 2.11）和可操作性（3.00 vs 2.22）上明显优于 D（因果图），而 D 的可读性略高（2.56 vs 2.33），总体 C 更具解释优势。该结果与行为代理（定位精度 loc_top1，见第 V 节）方向一致，但论文不将单模型主观评分解读为客观可解释性度量，仅作为探索性参考。

K. 跨模型鲁棒性

发现 6：证据表征的定位优势是模型依赖且受数据卫生强烈调节的（表 VI）。主实验在无泄漏口径下用 DeepSeek v4-flash（temperature=0.2）对 34 个 L3 样本的 A/B/C 三设置各跑 3 个 seeds（306 次调用，成本 \$1.57，

全部 BMC 三通过, T2 306/306): 总体定位 60.1%, 按设置 $A\ 64.7\% > C\ 59.8\% > B\ 55.9\%$, 配对检验均不显著。与旧泄漏版 ($A\ 51.0\%$ 、 $B\ 54.9\%$ 、 $C\ 62.7\%$) 相比, 68 处 loc_top1 翻转且“B 显著最优”被推翻——泄漏主要虚增了 B 的相对定位优势。MiniMax M3 的干净复跑为后续工作 (表 5 MM 列标注待复跑)。

方法论含义: 跨模型对比必须先统一修复判据口径; 若以旧 prove 判据 (通过率 74.3%) 对比 BMC 判据 (100%), 会错误得出“不同模型修复率差异显著”。统一 BMC 口径后该差异消失。这进一步支持本文的核心主张: 在判据可靠的前提下, 证据表征的相对效应应限定于所测模型, 论文不宣称跨模型普遍性。

VI. 结论

本文提出 PreCex, 一个开源、反例驱动的综合前 RTL 缺陷定位与修复流水线, 并系统研究了此前反例理解类系统未受控的证据表征维度。在干净口径 (无泄漏) 下, 以 DeepSeek v4-flash 在 34 样本跨周期 (L3) 基准上完成 408 次主实验 (A/B/C/D 四设置 $\times$ 3 seeds, 均为无泄漏口径) 与 72 次 L2 门禁对照, 主要结论如下:

- 统一 BMC 判据 (golden-first) 下, 四种证据表征的 BMC 回归通过率均达 100% (有限深度口径); 在干净数据上定位精度 $A\ 64.7\% > C\ 59.8\% > D\ 56.9\% > B\ 55.9\%$ (A/B/C 两两配对检验均不显著)——证据表征决定定位的精度与成本, 但效应被模型、数据卫生与反例时长共同调节: 深时序子集 (s39-s42) 上排序反转为 $C\ 75.0\% > A\ 66.7\% > D\ 58.3\% > B\ 41.7\%$ (第 V-I 节)。
- 评测双卫生是可靠结论的前提: ground-truth 泄漏 (三处) 使“B 显著最优”成为伪结论 (剥离后 68 处定位翻转、结论反转); prove/k-归纳判据失效会误判 78 个正确修复。数据卫生 (ground-truth 隔离) 与判据卫生 (golden-first) 已固化为评测协议。
- 修复可信度有据可依: 强变异 88.5%、常量变异 81.8% 被杀, 空泛性控制通过, T2 审计 306/306 通过 (接口/断言/证据闭环零违规), 定位偏差 (loc_dev) 中位数 0、精确命中 51.3%。
- 跨模型鲁棒性 (探索性): BMC 回归通过率跨模型一致 (100%), 但定位优势模型依赖——MiniMax 干净复跑待后续 (表 5 MM 列待补)。

未来工作包括: (1) 将动态自适应反例窗口 (失败时刻尾部回溯) 正式纳入主数据集评测, 并对深时序子集上的语义化增益做窗口策略与反例时长的正交消融 (本文第 V-I 节已提供初步证据: 深子集上 $C\ 75.0\% > A\ 66.7\%$); (2) 放宽最小化约束, 支持结构性重写候选 (拆分状态、增加中间态) 并与 delta-debugging 结合; (3) 顶层连接性审计: 将修复放回原网表/SoC 交互环境验证模块外副作用; (4) 多候选并发验证与在线仲裁 (探索与利用); (5) 向工业协议与更大断言集扩展、更强变异家族、多提供商多模型评测、GROVE 式跨样本知识层, 以及从“生成最小代码改动”向“生成更强的不变式约束”演进的修复范式; (6) 引入真正的根因诊断引擎——基于模型检验的反例轨迹切片与基于 SAT 的极小反例核心提取——使形式验证从“裁判”升级为“诊断指导”, 将修复范式从试错式 (trial-and-error) 推进为诊断驱动 (diagnosis-driven)。

A. 局限性

架构边界: 本方法的定位是“快速生成并验证候选补丁” (candidate patch generator), 而非“完全消除设计错误”。具体而言: (1) 修复成功定义为“反例消失”而非“不变式成立”——BMC 是有限深度的穷举测试, 不是完备性证明, 深度上界以外的错误仍可能存在; (2) “行级定位 + 最小 unified diff”的约束偏好局部修复——状态机拆分、增加中间态或重写状态转移条件等结构性重写可能需要十几行, 超出最小化约束, 这解释了为何状态迁移/握手类定位精度低 (31.2%–33.3%) 但 BMC 回归通过率仍为 100%——BMC 浅深度下小补丁可能绕过触发路径 (弱修复), 由 delta-debugging 与 T2 审计部分约束; (3) 验证为模块级, 无顶层互联/协议栈审计, 修复在模块外的副作用未覆盖; (4) 单流水线单候选, 3 seeds 是离线统计而非在线多候选仲裁。这四点均列入未来工作。

内部效度: 所有结果以 BMC 为主判据; 对带门控时序断言的模块, BMC 探测到缺陷深度加 2 并与 golden 验证交叉核对, 但 BMC 深度上界并非完备性保证 (深度敏感性抽查: 34 个样本的修复在 2 倍 BMC 深度下全部通过, 见 §V-F)。需要诚实声明: 该抽查覆盖全部样本的 2 倍深度而非更深边界, 不能证明所有修复在更大深度下仍通过; BMC 深度的选择对绝对通过率有影响——本文的结论是在 BMC 深度设为当前值的操作口径下得出的, 报告的是该口径下的相对比较结果。

判据翻案审计量化并修正了假阳性（误判正确修复为失败），但假阴性（错误修复因深度不足被漏判）的风险未被系统性量化，这是本判决的已知边界。LLM 推理是流水线唯一随机成分（3 seeds 配对统计），解析、提取与验证均为确定性。修复成功定义要求编译、弱测试平台回归与 BMC 无反例；不改变断言集的补丁仍可能在属性集之外改变行为，T2 审计通过接口与断言篡改检查约束该风险，但并非等价性检验。

外部效度：基准含 34 个教学级模块样本，不宣称工业协议覆盖；握手与状态迁移仍是最难定位类别（干净口径 47.2% 与 30.6%），uart_rx 的波特时序常量变异杀死率弱（常量 40.9%），是结构断言对时序常量漂移不敏感的已记录局限。常见模块可能出现在 LLM 训练语料中，本文以构造日期记录、逐样本来源与错误类别多样性缓解，但无法完全排除残余记忆。干净主实验 306 次运行均使用 DeepSeek v4-flash；初版 MiniMax M3 实验因数据泄漏整体作废，仅作为卫生教训的对照引用，其干净复跑待后续（表 5 MM 列待补），故本文的证据表征结论限定于所测模型与干净协议，绝对值可能随模型版本变化。另，L2 门禁对照的干净结果见 §V-E。

构造效度：loc_top1 记录模型首选中候选行是否落入注入缺陷的参考 diff；BMC 回归通过率按有限深度 BMC 判据计量；成本按 API token 记账；统计声明基于逐样本（样本 $\times$ seed）配对 McNemar 精确检验，报告全部六对对比并附 Holm 校正、Wilson 比例 95% 置信区间与率差效应量（含不显著项）。

参考文献

- [1] Y. Bai, G. B. Hamad, C.-T. Ho, S. Suhaib, and H. Ren, “FVDebug: An LLM-driven debugging assistant for automated root cause analysis of formal verification failures,” arXiv:2510.15906, 2025.
- [2] Y. Bai and H. Ren, “Learning to debug: LLM-organized knowledge trees for solving RTL assertion failures,” arXiv:2511.17833, 2025.
- [3] H. T. Tran, “Open-source LLM-driven formal verification: A multi-agent pipeline for RTL repair,” arXiv:2607.28877, 2026.
- [4] K. Li, M. Li, X. Wen, S. Zhao, J. Wu, J. Huang, and Q. Xu, “FormalRTL: Verified RTL synthesis at scale,” 2026. [Online]. Available: <https://formind.netlify.app/files/papers/FormalRTL.pdf>
- [5] WhaleChip, “WhaleChip uses ChipAgents to compress root cause analysis into minutes,” SemiWiki, 2026. [Online]. Available: <https://semiwiki.com/eda/chipagents-ai/371464-whalechip-uses-chipagents-to-compress-root-cause-analysis-into-minutes/>
- [6] Y. Wang, C. Liu, J. Zhang, L. Zhang, et al., “VeriPilot: An LLM-powered Verilog debugging framework,” arXiv:2606.23759, 2026.
- [7] N. Wang, B. Yao, J. Zhou, Y. Hu, et al., “VeriDebug: A unified LLM for Verilog debugging via contrastive embedding and guided correction,” arXiv:2504.19099, 2025.
- [8] Y.-D. Tsai, M. Liu, and H. Ren, “RTLFixer: Automatically fixing RTL syntax errors with large language models,” arXiv:2311.16543, 2023.
- [9] S. Li, W. Fu, Y. Zhao, X. Guo, and Y. Jin, “Fixbench-RTL: A comprehensive benchmark for evaluating LLMs on RTL debugging,” in Proc. IEEE AsianHOST, 2025, pp. 1–6.
- [10] “HDL-FixBench: A repository-scale RTL repair benchmark,” OpenReview preprint, 2026. [Online]. Available: <https://openreview.net/forum?id=omi6IH5N42>
- [11] W. Fang, M. Li, M. Li, Z. Yan, S. Liu, et al., “AssertLLM: Generating and evaluating hardware verification assertions from design specifications via multi-LLMs,” arXiv:2402.00386, 2024 (ASPAC 2025).
- [12] Y. Wu, W. Fang, J. Wang, W. Li, et al., “AssertLLM2: A comprehensive LLM benchmark for assertion generation from design specifications,” arXiv:2605.27472, 2026.
- [13] H. Lyu, Y. Wang, Y. Du, M. Shi, et al., “AssertGen: Enhancement of LLM-aided assertion generation through cross-layer signal bridging,” arXiv:2509.23674, 2025.
- [14] “LASSO: Safety property generation with vacuity checking and coverage feedback,” MLCAD 2025. [Online]. Available: <https://faculty.eng.ufl.edu/sandip/wp-content/uploads/sites/681/2026/02/mlcad25.pdf>
- [15] Z. Fang, R. Chen, Z. Yang, and Y. Guo, “LintLLM: An open-source Verilog linting framework based on large language models,” arXiv:2502.10815, 2025 (GLSVLSI 2025).
- [16] J. Kim, J. Byun, D. Hwang, S.-J. Park, and H. O. Song, “Rule2DRC: Benchmarking LLM agents for DRC script synthesis with execution-guided test generation,” arXiv:2605.15669, 2026 (ICML 2026).
- [17] P. Liu, N. Xu, J. Tang, Y. Cao, and C. Ding, “Bridging the last mile of circuit design: PostEDA-Bench, a hierarchical benchmark for PPA convergence,” arXiv:2605.06936, 2026.
- [18] J. Wang, L. J. Wan, S. Pingali, S. Smith, M. Jha, et al., “OpenRTLSet: A fully open-source dataset for large language model-based Verilog module design,” arXiv:2606.10285, 2026.
- [19] P. Shrestha, A. Aversa, and I. Savidis, “EDA-Schema-V2: A multimodal schema, open datasets, and benchmarks for machine learning in digital physical design,” arXiv:2605.06952, 2026.
- [20] L. Li, X. Yu, J. Ni, J. Zhu, J. Zhang, et al., “ChipLingo: A systematic training framework for large language models in EDA,” arXiv:2604.27415, 2026.
- [21] C. Wolf, “Yosys open synthesis suite,” 2013. [Online]. Available: <https://yosyshq.net/yosys/>
- [22] C. Wolf, “SymbiYosys (sby): A front-end for Yosys-based formal verification flows,” 2018. [Online]. Available: <https://github.com/YosysHQ/SymbiYosys>